

Wizualizacja danych z Pandas, Matplotlib i Seaborn

1. Import bibliotek

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
import seaborn as sns

# Ustawienia dla czytelności wykresów
plt.rcParams.update({'font.size': 12})
sns.set_style("whitegrid") # Styl seaborn
```

2. Przygotowanie danych

```
data = {
    "wojewodztwo": ["łódzkie", "łódzkie", "łódzkie", "łódzkie",
                   "łódzkie",
                   "mazowieckie", "mazowieckie", "mazowieckie",
                   "mazowieckie", "mazowieckie"],
    "rok": [2000, 2005, 2010, 2015, 2020,
            2000, 2005, 2010, 2015, 2020],
    "populacja_mln": [2.67, 2.59, 2.54, 2.49, 2.44,
                     5.07, 5.14, 5.24, 5.35, 5.42]
}
df_woj = pd.DataFrame(data)
df_woj.head(10)

{"summary": "{\\n  \\\"name\\\": \\\"df_woj\\\",\\n  \\\"rows\\\": 10,\\n  \\\"fields\\\": \\n    {\\n      \\\"column\\\": \\\"wojewodztwo\\\",\\n      \\\"properties\\\": {\\n        \\\"dtype\\\": \\\"category\\\",\\n        \\\"num_unique_values\\\": 2,\\n        \\\"samples\\\": [\\n          \\\"mazowieckie\\\",\\n          \\\"\\u0142\\u00f3dzkie\\\"\\n        ],\\n        \\\"semantic_type\\\": \\\"\\\",\\n        \\\"description\\\": \\\"\\\"\\n      }\\n    },\\n    {\\n      \\\"column\\\": \\\"rok\\\",\\n      \\\"properties\\\": {\\n        \\\"dtype\\\": \\\"number\\\",\\n        \\\"std\\\": 7,\\n        \\\"min\\\": 2000,\\n        \\\"max\\\": 2020,\\n        \\\"num_unique_values\\\": 5,\\n        \\\"samples\\\": [\\n          2005,\\n          2020\\n        ],\\n        \\\"semantic_type\\\": \\\"\\\",\\n        \\\"description\\\": \\\"\\\"\\n      }\\n    },\\n    {\\n      \\\"column\\\": \\\"populacja_mln\\\",\\n      \\\"properties\\\": {\\n        \\\"dtype\\\": \\\"number\\\",\\n        \\\"std\\\": 1.4264583181198578,\\n        \\\"min\\\": 2.44,\\n        \\\"max\\\": 5.42,\\n        \\\"num_unique_values\\\": 10,\\n        \\\"samples\\\": [\\n          5.35,\\n          2.59\\n        ],\\n        \\\"semantic_type\\\": \\\"\\\",\\n        \\\"description\\\": \\\"\\\"\\n      }\\n    }\\n  ]\\n}", "type": "dataframe", "variable_name": "df_woj"}
```

```

df_woj.keys()

Index(['województwo', 'rok', 'populacja_mln'], dtype='object')

# Filtracja danych dla każdego województwa
mazowieckie = df_woj[df_woj["województwo"] == "mazowieckie"]
lodzkie = df_woj[df_woj["województwo"] == "łódzkie"]

lodzkie

{"summary": "{\n  \"name\": \"łódzkie\",\n  \"rows\": 5,\n  \"fields\": [\n    {\n      \"column\": \"województwo\",\n      \"properties\": {\n        \"dtype\": \"category\",\n        \"num_unique_values\": 1,\n        \"samples\": [\n          \"\u0142\u00f3dzkie\"\n        ],\n        \"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    },\n    {\n      \"column\": \"rok\",\n      \"properties\": {\n        \"dtype\": \"number\",\n        \"std\": 7,\n        \"min\": 2000,\n        \"max\": 2020,\n        \"num_unique_values\": 5,\n        \"samples\": [\n          2005\n        ],\n        \"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    },\n    {\n      \"column\": \"populacja_mln\",\n      \"properties\": {\n        \"dtype\": \"number\",\n        \"std\": 0.08905054744357269,\n        \"min\": 2.44,\n        \"max\": 2.67,\n        \"num_unique_values\": 5,\n        \"samples\": [\n          2.59\n        ],\n        \"semantic_type\": \"\",\n        \"description\": \"\"\n      }\n    }\n  ],\n  \"type\": \"dataframe\",\n  \"variable_name\": \"łódzkie\"}

```

3. WYKRES LINIOWY (Line Plot)


Zastosowanie: Przedstawianie zmian w czasie, trendów

```


plt.plot(lodzkie["rok"], lodzkie["populacja_mln"], "bx-")
plt.xlabel("Rok")
plt.ylabel("Populacja [mln]")
plt.xlim([1999, 2021])

(1999.0, 2021.0)


```



```
fig, ax = plt.subplots(figsize=(8, 4))
ax.plot(lodzkie["rok"], lodzkie["populacja_mln"], 'bo-')
ax.set_xlabel("Rok")
ax.set_ylabel("pop [mln]")
Text(0, 0.5, 'pop [mln]')
```




```
fig, ax = plt.subplots(2, 1, figsize=(8, 4))
ax[0].plot(łódzkie["rok"], łódzkie["populacja_mln"], 'bo-')
ax[0].set_title("Łódzkie")
ax[1].plot(mazowieckie["rok"], mazowieckie["populacja_mln"], 'ro-')
ax[0].set_xlim([1999, 2022])
ax[1].set_xlim([1999, 2022])
ax[1].set_title("Mazowieckie")
plt.tight_layout()
```



Bezpośrednio plot na pandas DataFrame


```
lodzkie.plot(x="rok", y="populacja mln", marker="o", color="blue")
```

```
<Axes: xlabel='rok'>
```



```
fig, ax = plt.subplots(1, 2)
lodzkie.plot(x="rok", y="populacja mln", marker="o", color="blue",
ax=ax[0])
mazowieckie.plot(x="rok", y="populacja mln", marker="o", color="red",
ax=ax[1])
```

```
<Axes: xlabel='rok'>
```



4. WYKRES PUNKTOWY (Scatter Plot)


Zastosowanie: Pokazywanie relacji między dwiema zmiennymi

```
# Generowanie dodatkowych danych dla scatter plot
np.random.seed(42)
scatter_data = pd.DataFrame({
    'temperatura': np.random.uniform(15, 35, 1500),
    'sprzedaz_lodow': np.random.uniform(50, 300, 1500)
})
# Dodajemy korelację
scatter_data['sprzedaz_lodow'] = scatter_data['sprzedaz_lodow'] +
scatter_data['temperatura'] * 5

plt.figure(figsize=(8, 6))
plt.scatter(scatter_data['temperatura'],
scatter_data['sprzedaz_lodow'],
            s=50, alpha=0.6, c='coral', edgecolors='black',
linewidth=1)

plt.title('Zależność sprzedaży lodów od temperatury', fontsize=16,
fontweight='bold')
plt.xlabel('Temperatura [°C]', fontsize=14)
plt.ylabel('Sprzedaż lodów [szt.]', fontsize=14)
```

```
plt.ylim([50, 550])
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```



5. WYKRES SŁUPKOWY (Bar Plot)

Zastosowanie: Porównywanie wartości między kategoriami

```
# Dane dla wykresu słupkowego - populacja miast w dwóch różnych latach
miasta_data = pd.DataFrame({
    'miasto': ['Warszawa', 'Kraków', 'Łódź', 'Wrocław', 'Poznań'],
    'populacja_2022': [1795, 800, 670, 672, 545],
    'populacja_2010': [1700, 757, 730, 632, 550]
})


# Bar plot - Pandas

miasta_data.plot.bar(x='miasto', y=['populacja_2010',
    'populacja_2022'],
    figsize=(8, 4), color=['steelblue', 'coral'],
```

```

alpha=0.8)
plt.title('Bar plot z pandas - porównanie lat', fontsize=16,
fontweight='bold')
plt.xlabel('Miasto', fontsize=14)
plt.ylabel('Populacja [tys.]', fontsize=14)
plt.legend(['Populacja 2022', 'Populacja 2010'], fontsize=12)
plt.xticks(rotation=0)
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()

```




Jak to zrobić z Seaborn?

```

plt.figure(figsize=(8, 4))
sns.lineplot(data=df_woj, x='rok', y='populacja mln',
hue='województwo',
style='województwo', markers=True, dashes=False,
linewidth=2.5)


plt.title('Populacja - wykres z seaborn', fontsize=16,
fontweight='bold')
plt.xlabel('Rok', fontsize=14)
plt.ylabel('Populacja [mln]', fontsize=14)
plt.xticks([2000, 2010, 2020])
plt.tight_layout()
plt.show()

```



```
plt.figure(figsize=(8, 4))
sns.scatterplot(data=scatter_data, x='temperatura',
y='sprzedaz_lodow',
                s=100, alpha=0.7, color='purple')
sns.regplot(data=scatter_data, x='temperatura', y='sprzedaz_lodow',
            scatter=False, color='red', line_kws={'linewidth': 2})

plt.title('Scatter plot z seaborn + linia trendu', fontsize=16,
fontweight='bold')
plt.xlabel('Temperatura [°C]', fontsize=14)
plt.ylabel('Sprzedaż lodów [szt.]', fontsize=14)
plt.ylim([50, 550])
plt.tight_layout()
plt.show()
```




```
# Bar plot - Seaborn
```

```
# Przekształcenie danych do formatu długiego (long format)
```

```
miasta_long = pd.melt(miasta_data, id_vars=['miasto'],
                      value_vars=['populacja_2010', 'populacja_2022'],
                      var_name='Typ', value_name='Wartość')
```

```
plt.figure(figsize=(8, 4))
sns.barplot(data=miasta_long, x='miasto', y='Wartość', hue='Typ',
            palette='Set2')
plt.title('Bar plot z seaborn', fontsize=16, fontweight='bold')
plt.xlabel('Miasto', fontsize=14)
plt.ylabel('Wartość', fontsize=14)
plt.legend(title='Metryka', labels=['Populacja 2010 [tys.]',
                                   'Populacja 2022 [tys.]'], fontsize=11)
plt.tight_layout()
plt.show()
```



ZADANIA

Zadanie 1: Podstawy DataFrame i wykres liniowy

Dane: Liczba mieszkańców Warszawy i Łodzi w wybranych latach:

Rok	Warszawa	Łódź
2002	1672000	789318
2011	1707000	728892
2015	1740000	700982
2022	1795000	670642

Polecenia:

1. Utwórz słownik z powyższymi danymi
2. Stwórz DataFrame z tego słownika
3. **Stwórz wykres liniowy** pokazujący zmiany populacji obu miast w czasie
 - Użyj różnych kolorów i markerów dla każdego miasta
 - Dodaj tytuł, opisy osi i legendę
 - Wypróbuj wszystkie 3 metody (matplotlib, pandas, seaborn)

```
dane_miasta = {
    'Rok': [2002, 2011, 2015, 2022],
    'Warszawa': [1672000, 1707000, 1740000, 1795000],
    'Łódź': [789318, 728892, 700982, 670642]
}

df_miasta = pd.DataFrame(dane_miasta)
```

```

print("DataFrame z danymi miast:")
print(df_miasta)

print("\n Polecenie 3")

df_miasta_plot = df_miasta.set_index('Rok')

plt.figure(figsize=(8, 4))
plt.plot(df_miasta['Rok'], df_miasta['Warszawa'], 'o-', color='blue',
label='Warszawa')
plt.plot(df_miasta['Rok'], df_miasta['Łódź'], 'x--', color='red',
label='Łódź')

plt.title('Zmiany populacji Warszawy i Łodzi (Matplotlib)',
fontsize=16, fontweight='bold')
plt.xlabel('Rok', fontsize=12)
plt.ylabel('Populacja', fontsize=12)
plt.legend()
plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()

df_miasta_plot = df_miasta.set_index('Rok')

plt.figure(figsize=(8, 4))
df_miasta_plot.plot(kind='line', marker='o', ax=plt.gca(),
color=['blue', 'red'], style=['-', '--'])

plt.title('Zmiany populacji Warszawy i Łodzi (Pandas)', fontsize=16,
fontweight='bold')
plt.xlabel('Rok', fontsize=12)
plt.ylabel('Populacja', fontsize=12)
plt.legend(['Warszawa', 'Łódź'])
plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()

df_miasta_long = df_miasta.melt(id_vars=['Rok'], var_name='Miasto',
value_name='Populacja')

plt.figure(figsize=(8, 4))
sns.lineplot(data=df_miasta_long, x='Rok', y='Populacja',
hue='Miasto', style='Miasto', markers=True, dashes=False,
linewidth=2.5)

plt.title('Zmiany populacji Warszawy i Łodzi (Seaborn)', fontsize=16,
fontweight='bold')
plt.xlabel('Rok', fontsize=12)


```



```
plt.ylabel('Populacja', fontsize=12)
plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```

DataFrame z danymi miast:

	Rok	Warszawa	Łódź
0	2002	1672000	789318
1	2011	1707000	728892
2	2015	1740000	700982
3	2022	1795000	670642

Polecenie 3





Zadanie 2: Analiza danych o pojazdach w Łodzi

Dane pochodzą z portalu otwartych danych miasta Łodzi:

https://otwarte.miasto.lodz.pl/transport_komunikacja/

Do zrobienia:

1. **Wczytaj plik** `Pojazdy-ogolem-w-Lodzi.csv`
2. **Utwórz wykres punktowy** pokazujący zmianę liczby:
 - samochody osobowe
 - autobusy ogółemna przestrzeni lat. Dla każdego typu zrób osobny wykres.

3. Utwórz wykres słupkowy dla roku 2020 przedstawiający liczbę:

- autobusów
- samochodów osobowych
- samochodów ciężarowych
- motocykli

```
df = pd.read_csv('pojazdy-ogolem-w-Lodzi.csv', sep=';')
df.columns = ['nazwa_zbioru', 'rok', 'wartosc', 'typ_pojazdu']

samochody_osobowe_df = df[df['typ_pojazdu'] == 'samochody osobowe']

plt.figure(figsize=(10, 3))
sns.scatterplot(data=samochody_osobowe_df, x='rok', y='wartosc',
s=100, color='blue', alpha=0.7)
sns.lineplot(data=samochody_osobowe_df, x='rok', y='wartosc',
color='blue', linestyle='--')
plt.title('Zmiana liczby samochodów osobowych w Łodzi na przestrzeni
lat', fontsize=16, fontweight='bold')
plt.xlabel('Rok', fontsize=14)
plt.ylabel('Liczba samochodów osobowych', fontsize=14)
plt.xticks(samochody_osobowe_df['rok'].unique().astype(int))
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

autobusy_ogolem_df = df[df['typ_pojazdu'] == 'autobusy ogółem']



plt.figure(figsize=(10, 3))
sns.scatterplot(data=autobusy_ogolem_df, x='rok', y='wartosc', s=100,
color='green', alpha=0.7)
sns.lineplot(data=autobusy_ogolem_df, x='rok', y='wartosc',
color='green', linestyle='--')
plt.title('Zmiana liczby autobusów ogółem w Łodzi na przestrzeni lat',
fontsize=16, fontweight='bold')
plt.xlabel('Rok', fontsize=10)
plt.ylabel('Liczba autobusów ogółem', fontsize=10)
plt.xticks(autobusy_ogolem_df['rok'].unique().astype(int))
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()

df_2020 = df[df['rok'] == 2020]

typy_pojazdow = ['autobusy ogółem', 'samochody osobowe', 'samochody
ciężarowe', 'motocykle ogółem']
df_2020_wybrane = df_2020[df_2020['typ_pojazdu'].isin(typy_pojazdow)]

plt.figure(figsize=(10, 8))
sns.barplot(x='typ_pojazdu', y='wartosc', data=df_2020_wybrane)
```

```
plt.title('Liczba wybranych pojazdów w Łodzi w roku 2020',
fontsize=16, fontweight='bold')
plt.xlabel('Typ pojazdu', fontsize=10)
plt.ylabel('Liczba pojazdów', fontsize=10)
plt.xticks(rotation=45, ha='right')
plt.grid(axis='y', alpha=0.3)
plt.tight_layout()
plt.show()
```



Liczba wybranych pojazdów w Łodzi w roku 2020

