

Elementy odstające (*outliers*)

Kontekst ćwiczeń: Pracujemy z danymi sprzedażowymi sklepu internetowego.
Cel: zidentyfikować nietypowe obserwacje, zrozumieć ich przyczyny i podjąć decyzję — usunąć, skorygować czy zachować.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy import stats

pd.set_option('display.max_rows', 40)
pd.set_option('display.float_format', '{:.2f}'.format)
plt.rcParams['figure.dpi'] = 100
plt.rcParams['font.size'] = 11

np.random.seed(42)
```

Czym są elementy odstające?

Element odstający (outlier) to obserwacja, która znacząco odbiega od pozostałych danych. Może wynikać z:

- **błędu pomiaru / wpisu** — literówka, awaria czujnika, podwójne zaksięgowanie
- **rzeczywistego zdarzenia** — wyprzedaż Black Friday, awaria serwera, viralowy post
- **zmiany procesu** — nowa kampania reklamowa, zmiana cen, wejście na nowy rynek

Dlaczego to ważne?

Outliersy mogą poważnie wpływać na analizę statystyczną i modele predykcyjne: średnia arytmetyczna, odchylenie standardowe, regresja liniowa — wszystko to jest wrażliwe na wartości ekstremalne. Jednocześnie outliersy mogą nieść **cenną informację biznesową**, więc nie zawsze należy je usuwać.

Typy elementów odstających

Typ	Opis	Przykład
Jednowymiarowy	Ekstremalna wartość jednej zmiennej	Sprzedaż 5× wyższa niż zwykle
Wielowymiarowy	Nietypowa kombinacja zmiennych (każda z osobna OK)	Klient 22-letni z dochodem 500 tys. zł
Kontekstowy	Wartość normalna w jednym kontekście, odstająca w innym	200 sztuk w poniedziałek vs 200 sztuk w niedzielę

Metody wykrywania elementów odstających

#	Metoda	Typ	Założenia
1	Wykres pudełkowy (Boxplot)	wizualna	brak
2	Metoda IQR	statystyczna, nieparametryczna	brak
3	Z-score	statystyczna, parametryczna	rozkład normalny
4	Zmodyfikowany Z-score (MAD)	statystyczna, odporna (robust)	brak
5	Percentyle	statystyczna, nieparametryczna	brak

Przykład

```
# Wynagrodzenia brutto (tys. zł) – 24 pracowników małej firmy IT
df = pd.DataFrame({
    'pracownik': [
        'Anna', 'Bartek', 'Celina', 'Dawid', 'Ewa',          # juniorzy
        'Filip', 'Gosia', 'Hubert', 'Iwona', 'Jakub',        # regularni
        'Kasia', 'Lena', 'Marcin', 'Natalia', 'Oskar',       # regularni
        'Patryk', 'Robert', 'Sylwia', 'Tomek', 'Urszula',    # seniorzy
        'Wiktor',                                           #
        'Zuzia',                                           #
        'Dyrektor',                                         # CEO
        'Gosia_2',                                         # ← błąd
    ],
    'wynagrodzenie': [
        4.2, 4.5, 4.8, 5.0, 5.1,
        5.3, 5.5, 5.5, 5.8, 6.0,
        6.2, 6.3, 6.5, 6.8, 7.0,
        7.2, 7.5, 8.0, 8.5, 9.0,
        12.0,
        1.8,
        25.0,
        55.0,
    ]
})

wyn = df['wynagrodzenie']
```

```

print("DANE: wynagrodzenia pracowników (tys. zł)")
print("=" * 50)
print(df.to_string(index=False))
print(f"\nLiczba obserwacji: {len(df)}")

wyn = df['wynagrodzenie']
print(f"\nŚrednia: {wyn.mean():.2f} tys. zł")
print(f"Mediana: {wyn.median():.2f} tys. zł")
print(f"Std: {wyn.std():.2f} tys. zł")
print(f"Min: {wyn.min():.2f} tys. zł")
print(f"Max: {wyn.max():.2f} tys. zł")

print(f"\n→ Średnia ({wyn.mean():.1f}) jest wyraźnie wyższa od mediany ({wyn.median():.1f})")
print(" – to już sygnał, że w danych mogą być outliery górne!")

```

DANE: wynagrodzenia pracowników (tys. zł)

```

=====
pracownik  wynagrodzenie
Anna        4.20
Bartek      4.50
Celina      4.80
Dawid       5.00
Ewa         5.10
Filip       5.30
Gosia       5.50
Hubert      5.50
Iwona       5.80
Jakub       6.00
Kasia       6.20
Lena        6.30
Marcin      6.50
Natalia     6.80
Oskar       7.00
Patryk      7.20
Robert      7.50
Sylwia      8.00
Tomek       8.50
Urszula     9.00
Wiktor     12.00
Zuzia       1.80
Dyrektor   25.00
Gosia_2    55.00

```

Liczba obserwacji: 24

```

Średnia:  9.10 tys. zł
Mediana:  6.25 tys. zł
Std:      10.67 tys. zł
Min:      1.80 tys. zł

```

Max: 55.00 tys. zł

→ Średnia (9.1) jest wyraźnie wyższa od mediany (6.2)
– to już sygnał, że w danych mogą być outliersy górne!


Boxplot metoda

Metoda 1: Wykres pudełkowy (Boxplot)

Boxplot wizualizuje rozkład danych przez kwartyle. Elementy poza „wąsami” ($1.5 \times \text{IQR}$ od krawędzi pudełka) traktowane są jako potencjalne outliersy.

Jest to jednocześnie **wizualizacja** i **metoda detekcji** — idealna na początek.

```
fig, ax = plt.subplots(figsize=(8, 4))
bp_vertical = ax.boxplot(df['wynagrodzenie'])
ax.set_xlabel('Wynagrodzenie (tys. zł)')
ax.set_title('Boxplot — wynagrodzenia pracowników')
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```




```
fig, ax = plt.subplots(figsize=(8, 4))
bp_horizontal = ax.boxplot(df['wynagrodzenie'], vert=False,
                             patch_artist=True,
                             boxprops=dict(facecolor='lightblue',
                                             edgecolor='navy'),
                             flierprops=dict(marker='o', markerfacecolor='red',
```

```

markersize=10))
ax.set_xlabel('Wynagrodzenie (tys. zł)')
ax.set_title('Boxplot — wynagrodzenia pracowników')
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()

```



Metoda 2: Rozstęp ćwiartkowy (IQR)

Wzór:

$$IQR = Q_3 - Q_1$$

Granice:

- dolna: $Q_1 - 1.5 \times IQR$
- górna: $Q_3 + 1.5 \times IQR$

Wartości poza granicami uznajemy za outliersy. Metoda **nieparametryczna** — nie wymaga rozkładu normalnego. To ta sama logika, którą stosuje boxplot.

```

wyn = df['wynagrodzenie']
Q1 = wyn.quantile(0.25)
Q3 = wyn.quantile(0.75)
IQR = Q3 - Q1
dolny_limit = Q1 - 1.5 * IQR
gorny_limit = Q3 + 1.5 * IQR

print("METODA IQR")
print("=" * 50)
print(f"Q1 = {Q1:.2f}")

```

```

print(f"Q3 = {Q3:.2f}")
print(f"IQR = {IQR:.2f}")
print(f"\nDolny limit = {Q1:.2f} - 1.5 × {IQR:.2f} = {dolny_limit:.2f}")
print(f"Górny limit = {Q3:.2f} + 1.5 × {IQR:.2f} = {gorny_limit:.2f}")

maska_iqr = (wyn < dolny_limit) | (wyn > gorny_limit)
print(f"\nWykryte outliersy ({maska_iqr.sum()}):")
print(df[maska_iqr][['pracownik', 'wynagrodzenie']].to_string(index=False))

```

METODA IQR

```

=====
Q1 = 5.25
Q3 = 7.62
IQR = 2.38

```

```

Dolny limit = 5.25 - 1.5 × 2.38 = 1.69
Górny limit = 7.62 + 1.5 × 2.38 = 11.19

```

Wykryte outliersy (3):

pracownik	wynagrodzenie
Wiktor	12.00
Dyrektor	25.00
Gosia_2	55.00

Metoda 3: Z-score (standaryzacja)

Wzór:

$$z_i = \frac{x_i - \bar{x}}{s}$$

Wartość $|z| > 3$ oznacza, że obserwacja leży ponad 3 odchylenia standardowe od średniej — w rozkładzie normalnym dotyczy to < 0.3% danych.

Uwaga: Średnia i odchylenie standardowe **są wrażliwe na outliersy**, więc skrajne wartości „rozciągają” skalę i mogą maskować umiarkowane anomalie.

```

z_scores = np.abs(stats.zscore(wyn))
df['z_score'] = z_scores

print("METODA Z-SCORE")
print("=" * 50)
print(f"Średnia (x̄) = {wyn.mean():.2f}")
print(f"Odch. std (s) = {wyn.std():.2f}")

maska_z3 = z_scores > 3
maska_z2 = z_scores > 2

```

```
print(f"\nOutliersy (|z| > 3): {maska_z3.sum()}")
if maska_z3.sum() > 0:
    print(df[maska_z3][['pracownik', 'wynagrodzenie',
'z_score']].to_string(index=False))

print(f"\nPotencjalne outliersy (|z| > 2): {maska_z2.sum()}")
if maska_z2.sum() > 0:
    print(df[maska_z2][['pracownik', 'wynagrodzenie',
'z_score']].to_string(index=False))

print("\n→ Wartość 55.0 (Gosia_2) tak mocno zawyża std,")
print(" że np. Zuzia (1.8) czy Dyrektor (25.0) mogą nie wyjść jako outliersy!")
```

METODA Z-SCORE

```
=====
```

Średnia ($\bar{x}$) = 9.10

Odch. std (s) = 10.67

```
Outliersy (|z| > 3): 1
pracownik  wynagrodzenie  z_score
Gosia_2      55.00      4.39
```

```
Potencjalne outliersy (|z| > 2): 1
pracownik  wynagrodzenie  z_score
Gosia_2      55.00      4.39
```

→ Wartość 55.0 (Gosia_2) tak mocno zawyża std,
 że np. Zuzia (1.8) czy Dyrektor (25.0) mogą nie wyjść jako outliersy!

Metoda 4: Zmodyfikowany Z-score (MAD)

Klasyczny Z-score używa średniej i std, które same są wrażliwe na outliersy. **Zmodyfikowany Z-score** zastępuje je odporniejszymi odpowiednikami:

$$MAD = \text{median}(|x_i - \tilde{x}|)$$

$$M_i = \frac{0.6745 \cdot (x_i - \tilde{x})}{MAD}$$

Próg: $|M_i| > 3.5$ (zalecenie Iglewicz i Hoaglina, 1993).

Kluczowa różnica: **mediana i MAD nie zmieniają się** pod wpływem jednej ekstremalnej wartości — dlatego metoda jest **odporna (robust)**.

```
mediana = wyn.median()
mad = np.median(np.abs(wyn - mediana))
modified_z = np.abs(0.6745 * (wyn - mediana) / mad)
```

```

df['mod_z_score'] = modified_z

print("METODA MAD (Zmodyfikowany Z-score)")
print("=" * 50)
print(f"Mediana = {mediana:.2f}")
print(f"MAD      = {mad:.2f}")

maska_mad = modified_z > 3.5
print(f"\nOutliersy (|M| > 3.5): {maska_mad.sum()}")
if maska_mad.sum() > 0:
    print(df[maska_mad][['pracownik', 'wynagrodzenie',
                        'mod_z_score']].to_string(index=False))

print("\n→ MAD wykrywa więcej anomalii niż Z-score,")
print("    bo Gosia_2 (55.0) nie zaburza miar bazowych.")

METODA MAD (Zmodyfikowany Z-score)
=====
Mediana = 6.25
MAD      = 1.20

Outliersy (|M| > 3.5): 2
pracownik  wynagrodzenie  mod_z_score
Dyrektor      25.00        10.54
Gosia_2       55.00        27.40

→ MAD wykrywa więcej anomalii niż Z-score,
  bo Gosia_2 (55.0) nie zaburza miar bazowych.

```

Metoda 5: Percentyle

Najprostsza metoda: odcinamy skrajne wartości na wybranym progu procentowym.

- **Rygorystycznie:** poniżej 1. i powyżej 99. percentyla
- **Łagodnie:** poniżej 5. i powyżej 95. percentyla

Metoda przydatna szczególnie przy **winzorowaniu** — zastępowaniu ekstremalnych wartości wartościami granicznymi.

```

print("METODA PERCENTYLI")
print("=" * 50)

for dolny_p, gorny_p in [(1, 99), (5, 95)]:
    p_low = wyn.quantile(dolny_p / 100)
    p_high = wyn.quantile(gorny_p / 100)
    maska = (wyn < p_low) | (wyn > p_high)

    print(f"\nPróg {dolny_p}–{gorny_p} percentyl:")
    print(f"  Dolna granica = {p_low:.2f}")
    print(f"  Górna granica = {p_high:.2f}")

```



```
print(f" Wykryte outliersy: {maska.sum()}")
if maska.sum() > 0:
    print(df[maska][['pracownik',
'wynagrodzenie']].to_string(index=False))
```

METODA PERCENTYLI

```
=====
```

Próg 1–99 percentyl:

Dolna granica = 2.35

Górna granica = 48.10

Wykryte outliersy: 2

pracownik	wynagrodzenie
Zuzia	1.80
Gosia_2	55.00

Próg 5–95 percentyl:

Dolna granica = 4.25

Górna granica = 23.05

Wykryte outliersy: 4

pracownik	wynagrodzenie
Anna	4.20
Zuzia	1.80
Dyrektor	25.00
Gosia_2	55.00

Outliersy wielowymiarowe

W praktyce anomalie często ujawniają się dopiero gdy spojrzymy na **kombinację zmiennych**. Każda zmienna z osobna może wyglądać normalnie, ale ich **połączenie** jest nietypowe.

```
# Dane: doświadczenie (lata) vs wynagrodzenie
df_2d = pd.DataFrame({
    'pracownik': ['Anna', 'Bartek', 'Celina', 'Dawid', 'Ewa',
                  'Filip', 'Gosia', 'Hubert', 'Iwona', 'Jakub',
                  'Kasia', 'Lena'],
    'doswiadczenie': [1, 2, 3, 5, 7, 8, 10, 12, 15, 3, 6, 20],
    'wynagrodzenie': [4.5, 5.0, 5.5, 6.5, 7.0, 7.5, 8.0, 9.0, 10.0,
12.0, 4.0, 8.0]
})

print("DANE: doświadczenie vs wynagrodzenie")
print("=" * 45)
print(df_2d.to_string(index=False))

# Z-score per kolumna
z_dosw = np.abs(stats.zscore(df_2d['doswiadczenie']))
z_wyn = np.abs(stats.zscore(df_2d['wynagrodzenie']))
df_2d['outlier'] = (z_dosw > 2) | (z_wyn > 2)
```

```

print(f"\n→ Jakub: 3 lata doświadczenia, a zarabia 12.0 –
protegowany?")
print(f"→ Kasia: 6 lat doświadczenia, a zarabia 4.0 – niedoceniana?")
print(f"→ Lena: 20 lat i tylko 8.0 – stagnacja?")
print(f"\n Żadna z tych wartości nie jest ekstremalna SAMA W SOBIE,")
print(f" ale ich KOMBINACJA jest podejrzana!")

```

Scatter plot

```
fig, ax = plt.subplots(figsize=(8, 6))
```

```
normalne = df_2d[~df_2d['outlier']]
```

```
outl = df_2d[df_2d['outlier']]
```

```
ax.scatter(normalne['doswiadczenie'], normalne['wynagrodzenie'],
           s=80, color='steelblue', label='Normalne')
```

Zaznacz interesujące przypadki ręcznie

```

for _, row in df_2d.iterrows():
    if row['pracownik'] in ['Jakub', 'Kasia', 'Lena']:
        ax.scatter(row['doswiadczenie'], row['wynagrodzenie'],
                   s=150, color='red', marker='X', zorder=5)
        ax.annotate(f"{row['pracownik']} ({row['doswiadczenie']}l,
{row['wynagrodzenie']}k)",
                    (row['doswiadczenie'], row['wynagrodzenie']),
                    textcoords="offset points", xytext=(10, 5),
                    fontsize=9, color='red')

```

Linia trendu

```

z = np.polyfit(df_2d['doswiadczenie'], df_2d['wynagrodzenie'], 1)
x_line = np.linspace(0, 22, 100)
ax.plot(x_line, np.polyval(z, x_line), 'g--', alpha=0.5, label='Trend
liniowy')

```

```
ax.scatter([], [], s=150, color='red', marker='X', label='Podejrzane
przypadki')
```

```
ax.set_xlabel('Doświadczenie (lata)')
```

```
ax.set_ylabel('Wynagrodzenie (tys. zł)')
```

```
ax.set_title('Outliersy wielowymiarowe – doświadczenie vs
wynagrodzenie')
```

```
ax.legend()
```

```
ax.grid(True, alpha=0.3)
```

```
plt.tight_layout()
```

```
plt.show()
```

DANE: doświadczenie vs wynagrodzenie

=====

pracownik	doswiadczenie	wynagrodzenie
-----------	---------------	---------------


Anna	1	4.50
------	---	------

Bartek	2	5.00
--------	---	------

Celina	3	5.50
Dawid	5	6.50
Ewa	7	7.00
Filip	8	7.50
Gosia	10	8.00
Hubert	12	9.00
Iwona	15	10.00
Jakub	3	12.00
Kasia	6	4.00
Lena	20	8.00

- Jakub: 3 lata doświadczenia, a zarabia 12.0 – protegowany?
- Kasia: 6 lat doświadczenia, a zarabia 4.0 – niedoceniana?
- Lena: 20 lat i tylko 8.0 – stagnacja?

Żadna z tych wartości nie jest ekstremalna SAMA W SOBIE,
ale ich KOMBINACJA jest podejrzana!



Zadanie

Plik `sprzedaz_dzienna.csv` zawiera **90 dni** danych sprzedażowych sklepu internetowego z kolumnami: `sprzedaz`, `dzien_tygodnia`, `przychod`, `wizyty`, `zwroty`.

Polecenia:

1. Wczytaj dane i wyświetl podstawowe statystyki opisowe (wszystkie kolumny numeryczne).
2. Narysuj serię czasową sprzedaży oraz boxplot — ogólny i wg dnia tygodnia.
3. Zastosuj **trzy metody** wykrywania outlierów dla kolumny `sprzedaz`: IQR, Z-score, MAD. Porównaj wyniki.
4. Zbadaj **outliersy wielowymiarowe**: zrób scatter plot `wizyty` vs `sprzedaz` — czy widzisz nietypowe kombinacje?
5. Sprawdź kolumnę `zwroty` — czy widzisz dni z podejrzeniem wysokim procentem zwrotów względem sprzedaży?
6. Dla każdego wykrytego outliera zaproponuj hipotezę: co mogło się stać?
7. Zaproponuj strategię postępowania z każdym outlierem (usunąć / skorygować / zachować / oznaczyć).

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy import stats

# 1.
df = pd.read_csv('sprzedaz_dzienna.csv')
print("Statystyki opisowe:")
print(df.describe())

# 2.
fig, (ax1, ax2, ax3) = plt.subplots(3, 1, figsize=(12, 18))

ax1.plot(df.index, df['sprzedaz'], marker='o', linestyle='--')
ax1.set_title('Seria czasowa sprzedaży (90 dni)')
ax1.set_ylabel('Liczba sprzedanych sztuk')

ax2.boxplot(df['sprzedaz'], vert=False)
ax2.set_title('Ogólny boxplot sprzedaży')

df.boxplot(column='sprzedaz', by='dzien_tygodnia', ax=ax3)
ax3.set_title('Sprzedaż w podziale na dni tygodnia')
plt.suptitle('')
plt.show()

# 3.
sprzedaz = df['sprzedaz']

# Metoda IQR
Q1, Q3 = sprzedaz.quantile(0.25), sprzedaz.quantile(0.75)
```

```

IQR = Q3 - Q1
out_iqr = df[(sprzedaz < (Q1 - 1.5 * IQR)) | (sprzedaz > (Q3 + 1.5 *
IQR))]

# Metoda Z-score
z_scores = np.abs(stats.zscore(sprzedaz))
out_z = df[z_scores > 3]

# Metoda MAD
mediana = sprzedaz.median()
mad = np.median(np.abs(sprzedaz - mediana))
mod_z = 0.6745 * (sprzedaz - mediana) / mad
out_mad = df[np.abs(mod_z) > 3.5]

print(f"\nOutliery IQR: {len(out_iqr)}, Z-score: {len(out_z)}, MAD:
{len(out_mad)}")




# 4.
plt.figure(figsize=(10, 6))
plt.scatter(df['wizyty'], df['sprzedaz'], alpha=0.7)
plt.title('Relacja: Wizyty vs Sprzedaż')
plt.xlabel('Liczba wizyt')
plt.ylabel('Sprzedaż')
plt.grid(True)
plt.show()

# 5.
df['ratio_zwroty'] = (df['zwroty'] / df['sprzedaz']) * 100
print("\nDni z podejrzenie wysokim procentem zwrotów:")
print(df[['dzien_tygodnia', 'sprzedaz', 'zwroty',
'ratio_zwroty']].sort_values(by='ratio_zwroty',
ascending=False).head())


```

Statystyki opisowe:

	Unnamed: 0	sprzedaz	przychod	wizyty	zwroty
count	90.00	90.00	90.00	90.00	90.00
mean	44.50	163.03	9109.68	5214.49	8.60
std	26.12	53.75	4389.05	1723.74	4.18
min	0.00	8.00	442.06	410.00	1.00
25%	22.25	144.75	7575.17	4432.25	6.00
50%	44.50	163.00	8964.28	5066.00	8.00
75%	66.75	176.75	10060.07	5887.00	11.00
max	89.00	437.00	39900.00	14344.00	24.00



Outliery IQR: 9, Z-score: 2, MAD: 7



Dni z podejrzenie wysokim procentem zwrotów:

	dzien_tygodnia	sprzedaz	zwroty	ratio_zwroty
42	Mon	172	24	13.95
17	Thu	8	1	12.50
43	Tue	162	19	11.73
44	Wed	218	22	10.09
30	Wed	163	15	9.20